

Universität Duisburg-Essen
Software Engineering B.Sc.

User Identifikation Modell

Entwicklung eines Verhaltensbiometrie-
Identifikationssystems basierend auf Handtracking-Daten
in virtuellen Umgebungen

Intelligent User Interfaces

Prof. Dr. Stefan Schneegass

Vorgelegt von
Sara Arabi
Hozayfa Khleef

Inhalt Verzeichnis

1. Einleitung	3
1.1 Ziele des Projektes:	3
1.2 Überblick über den Inhalt der Dokumentation:.....	3
2. Datenanalyse	4
2.1 Datensätze	4
2.2 Datenvorbereitung und -bereinigung	4
2.3 Visualisierungen (Boxplots)	4
3. Feature-Engineering.....	5
3.1 Auswahl relevanter Features.....	5
3.2 Methoden zur Reduktion des Einflusses der Körpergröße.....	5
3.3 Normalisierung und Standardisierung der Daten	5
4. Modellierung	6
4.1 Versuch Eins: Einfaches DNN-Modell.....	6
4.2 Versuch Zwei: Komplexes CNN-LSTM-Modell	6
4.3 Versuch Drei: Komplexes LSTM-Modell.....	7
4.4 Versuch Vier: Endgültiges Modell.....	7
5. Training und Validierung des Modells	8
5.1 Trainingsstrategie.....	8
5.2 Training der Modelle.....	8
5.3 Validierungsstrategie	8
5.4 Evaluierung der Modelle	8
6. Validierungsergebnisse.....	8
6.1 Reposition-Modell	9
6.2 Context menu-Modell	10
6.3 Bimanuelle Keyboard-Modell:	11
6.4 rescale-Modell:	12
7. Optimierung	13
7.1 Window Slicing	13
7.2 Majority Voting.....	13
8. Test-Ergebnisse nach der Optimierung:.....	13
8.1 Reposition.....	14
8.2 Context menu.....	15
8.3 Bimanuale Keyboard.....	16
8.4 Rescale.....	17
9. Diskussion & Fazit	18
9.1 Diskussion	18
9.2 Fazit	18

1. Einleitung

In diesem Projekt geht es darum, ein Verhaltensbiometrie-Identifikationssystem zu entwickeln, das Benutzer anhand ihrer Verhaltensdaten in virtuellen Umgebungen identifiziert. Das Ziel des Projektes ist es, zwischen 16 Teilnehmern zu unterscheiden und verschiedene bimanuale Interaktionen zu analysieren, um am Ende entscheiden zu können, welcher Benutzer von den 16 es gewesen war. Dies ermöglicht eine sichere und benutzerfreundliche Authentifizierung in virtuellen Realitäten.

1.1 Ziele des Projektes:

Das Projekt nutzt Handtracking-Daten aus Virtual Reality (VR) Interaktionen. Dabei wird ein neuronales Netz implementiert, um 16 verschiedene Teilnehmer zu identifizieren. Ein Ziel des Projekts ist es, zukünftig auf Passwörter verzichten zu können, um Probleme wie das Vergessen von Passwörtern und die Notwendigkeit, diese an sicheren Orten zu speichern, zu vermeiden.

1.2 Überblick über den Inhalt der Dokumentation:

Die Dokumentation ist in mehrere Kapitel unterteilt, die einen umfassenden Überblick über die verschiedenen Aspekte des Projekts geben. Im Kapitel zur Datenanalyse werden die Datensätze beschrieben, die für das Projekt verwendet wurden, sowie die Schritte zur Datenvorbereitung und -bereinigung. Es beinhaltet auch eine deskriptive Analyse der Daten. Das Kapitel zum Feature-Engineering erläutert die Auswahl relevanter Features. Es werden Methoden zur Reduktion des Einflusses der Körpergröße sowie zur Normalisierung und Standardisierung der Daten vorgestellt. Im Kapitel zur Modellierung werden die verschiedenen Modellierungsansätze beschrieben, die im Verlauf des Projekts ausprobiert wurden. Dies umfasst sowohl einfache als auch komplexe Modelle sowie das endgültige Modell, das ausgewählt wurde. Das Kapitel Training und Validierung behandelt die Trainings- und Validierungsstrategien, einschließlich der Verwendung spezieller Callbacks und Evaluierungsmethoden. Im Kapitel Ergebnisse werden die Validierungsverluste, Genauigkeiten, Klassifikationsberichte und Verwirrungsmatrizen für die verschiedenen Modelle präsentiert. Das Kapitel Optimierung umfasst die Implementierung und den Nutzen spezieller Techniken wie Window Slicing und Majority Voting zur Verbesserung der

Modellleistung. Im Kapitel Ergebnisse nach der Optimierung wird zwischen den Ergebnissen von Klassifikationsberichten und Verwirrungsmatrizen der unterschiedlichen Interaktionen vor und nach der Nutzung von Window Slicing und Majority Voting unterschieden. Das abschließende Kapitel Diskussion und Fazit fasst die Ergebnisse zusammen, diskutiert die Herausforderungen und schlägt mögliche Verbesserungen für zukünftige Arbeiten vor.

2. Datenanalyse

2.1 Datensätze

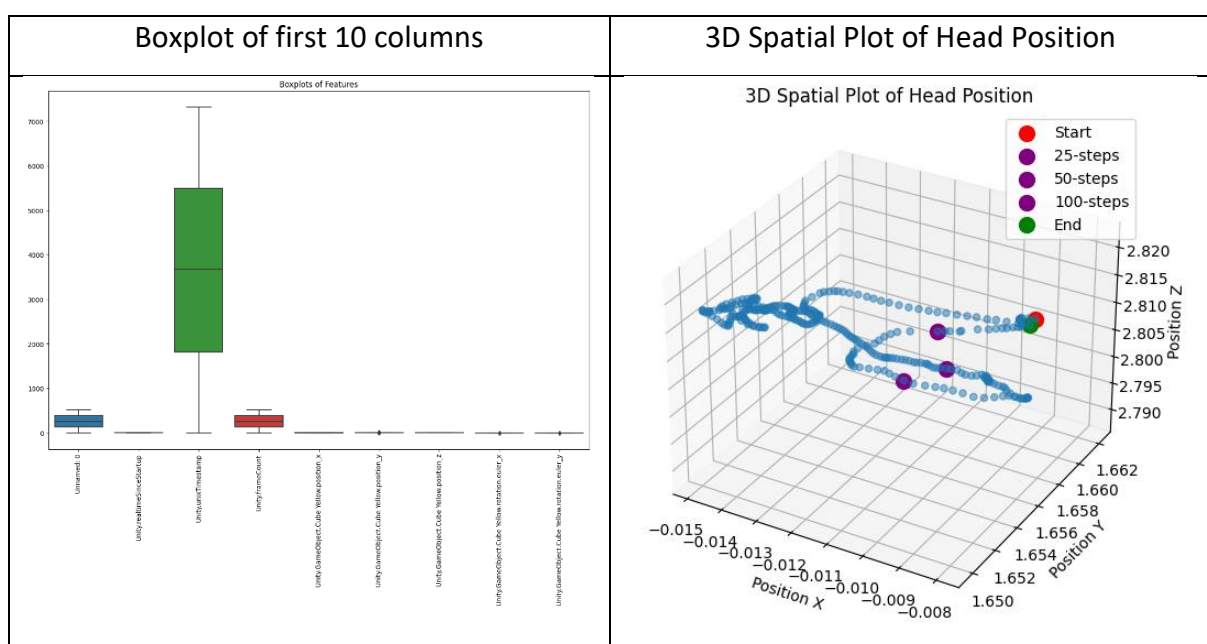
Der Datensatz besteht aus zwei Sitzungen (Session 1 und Session 2). Session 1 wird für das Training und die Validierung verwendet, während Session 2 ausschließlich für Tests verwendet wird. Die Daten umfassen Positionen und Rotationen von Hand- und Kopfbewegungen in verschiedenen Interaktionen gegen verschiedene Gegenstände.

2.2 Datenvorbereitung und -bereinigung

Laden der Daten: Die Daten wurden aus TSV-Dateien geladen, die die Hand- und Kopfpositionen sowie weitere relevante Informationen enthalten.

2.3 Visualisierungen

Eine deskriptive Analyse wurde durchgeführt, um einen Überblick über die Verteilung und die Eigenschaften der Daten zu erhalten.



3. Feature-Engineering

3.1 Auswahl relevanter Features

Es wurden wichtige Features aus dem Datensatz identifiziert und ausgewählt, die für die Identifikation der Benutzer relevant sind. Diese Auswahl konzentrierte sich auf die Positionen und Rotationen der Hand- und Kopfbewegungen sowie Reduktion des Einflusses der Körpergröße. Bestimmte Spalten, die keine relevanten Informationen für das Modell liefern oder potenziell zu Verwirrung führen könnten, wurden ausgeschlossen, wie Metadaten und NaNs.

3.2 Methoden zur Reduktion des Einflusses der Körpergröße

Um den Einfluss der Körpergröße zu minimieren, wurden folgende Methoden angewendet:

- **Positionsnormalisierung:** Alle Positionen wurden von ihrer initialen Position subtrahiert, um die Daten zu normalisieren und den Einfluss der Körpergröße zu eliminieren
- **Vektorenberechnung:** Vektoren von Kopf zu Hand/Finger wurden berechnet, um relative Positionen zu erfassen und damit ebenfalls den Einfluss der Körpergröße zu reduzieren.

3.3 Normalisierung und Standardisierung der Daten

Um sicherzustellen, dass die Daten für das Modell geeignet sind, wurden sie normalisiert und standardisiert. Dies umfasst die Entfernung von fehlenden Werten, die Skalierung der Daten und das Teilen der Daten in Fenster.

- **Entfernung von fehlenden Werten:** Zeilen mit fehlenden Werten wurden entfernt, um die Datenqualität zu gewährleisten.
- **One-Hot-Encoding der Zielvariablen:** Die Zielvariablen (Labels) wurden in ein One-Hot-Format umgewandelt, das für die Modellierung notwendig ist.
- **Skalierung der Eingabedaten:** Die Eingabedaten wurden mit '*StandardScaler*' skaliert, um sicherzustellen, dass alle Features vergleichbare Wertebereiche haben.

- **Teilen der Daten in Fenster:** Die Daten wurden in kleinere Fenster unterteilt, um die zeitliche Abfolge der Bewegungen mit Hilfe von 'Slicing-Window' Technik zu berücksichtigen.

4. Modellierung

In diesem Projekt wurden verschiedene Modellierungsansätze ausprobiert, um das beste Modell zur Identifikation von Benutzern anhand ihrer Handtracking-Daten zu finden. Hier sind die vier Versuche zur Modellierung beschrieben:

4.1 Versuch Eins: Einfaches DNN-Modell

- *Architektur des Netzwerks:*
Eingabeschicht (Input layer): Dense-Schicht mit 64 Neuronen
Verborgene Schichten (Hidden layers):
 - Dense-Schicht mit 32 Neuronen
 - Dense-Schicht mit 16 Neuronen**Ausgabeschicht (Output layer):** Dense-Schicht mit Anzahl der Klassen
- *Aktivierungsfunktionen:*
ReLU (Rectified Linear Unit) für die verborgenen Schichten
Softmax für die Ausgabeschicht
- *Hyperparameter:*
Lernrate: 0.001
Dropout-Rate: 0.3
Optimierer: Adam mit Gradient Clipping (clipvalue=1.0)

4.2 Versuch Zwei: Komplexes CNN-LSTM-Modell

- *Architektur des Netzwerks:*
Eingabeschicht (Input layer): Conv1D-Schicht mit 32 Filtern
Verborgene Schichten (Hidden layers):
 - Conv1D-Schicht mit 64 Filtern
 - LSTM-Schicht mit 50 Einheiten
 - Dense-Schicht mit 128 Neuronen**Ausgabeschicht (Output layer):** Dense-Schicht mit Anzahl der Klassen
- *Aktivierungsfunktionen:*
ReLU für die Conv1D- und Dense-Schichten
Softmax für die Ausgabeschicht
- *Hyperparameter:*
Lernrate: 0.0001
Dropout-Rate: 0.3

Optimierer: Adam

4.3 Versuch Drei: Komplexes LSTM-Modell

- *Architektur des Netzwerks:*
Eingabeschicht (Input layer): LSTM-Schicht mit 128 Einheiten
Verborgene Schichten (Hidden layers):
 - LSTM-Schicht mit 64 Einheiten
 - LSTM-Schicht mit 32 Einheiten**Ausgabeschicht (Output layer):** Dense-Schicht mit Anzahl der Klassen
- *Aktivierungsfunktionen:*
ReLU für die LSTM-Schichten
Softmax für die Ausgabeschicht
- *Hyperparameter:*
Lernrate: 0.0001
Dropout-Rate: 0.3
Optimierer: Adam

4.4 Versuch Vier: Endgültiges Modell

Das endgültige Modell wurde nach mehreren Versuchen und Evaluierungen als das leistungsfähigste Modell ausgewählt. Dieses Modell kombiniert LSTM-Schichten und Dense-Schichten und nutzt Dropout zur Regularisierung.

- *Architektur des Netzwerks:*
Eingabeschicht (Input layer): LSTM-Schicht mit 128 Einheiten
Verborgene Schichten (Hidden layers):
 - LSTM-Schicht mit 64 Einheiten
 - LSTM-Schicht mit 32 Einheiten
 - Dense-Schicht mit 64 Neuronen**Ausgabeschicht (Output layer):** Dense-Schicht mit Anzahl der Klassen
- *Aktivierungsfunktionen:*
ReLU für die LSTM- und Dense-Schichten
Softmax für die Ausgabeschicht
- *Hyperparameter:*
Lernrate: 0.001
Dropout-Rate: 0.3
Optimierer: Adam

5. Training und Validierung des Modells

5.1 Trainingsstrategie

Für das Training der Modelle wurde eine systematische Strategie angewendet, um die besten Ergebnisse zu erzielen. Diese Strategie umfasst die Erstellung und das Training separater Modelle für die Interaktionstypen (Reposition, Kontextmenü, Bimanuelle Tastatur, Reskalierung) und die Verwendung eines speziellen Callbacks zur Reduzierung der Lernrate bei Stagnation der Validierungsverluste.

5.2 Training der Modelle

Eine Funktion wurde definiert, um die Modelle zu trainieren. Diese Funktion verwendet den *'ReduceLROnPlateau'* Callback, um die Lernrate zu reduzieren, wenn die Validierungsverluste über mehrere Epochen hinweg nicht sinken. Dies hilft, die Modelle stabiler und effizienter zu trainieren.

5.3 Validierungsstrategie

Die Validierungsstrategie umfasst die Evaluierung der Modelle anhand von Validierungsdaten, die Berechnung von Verlust und Genauigkeit, das Erstellen von Klassifikationsberichten und Verwirrungsmatrizen. Diese umfassende Evaluierung hilft, die Leistung der Modelle detailliert zu analysieren und zu verstehen.

5.4 Evaluierung der Modelle

Eine Funktion wurde definiert, um die Modelle auf den Validierungsdaten zu evaluieren. Diese Funktion berechnet den Validierungsverlust und die Genauigkeit und erstellt detaillierte Klassifikationsberichte (Classification report) und Verwirrungsmatrizen (Confusion matrix).

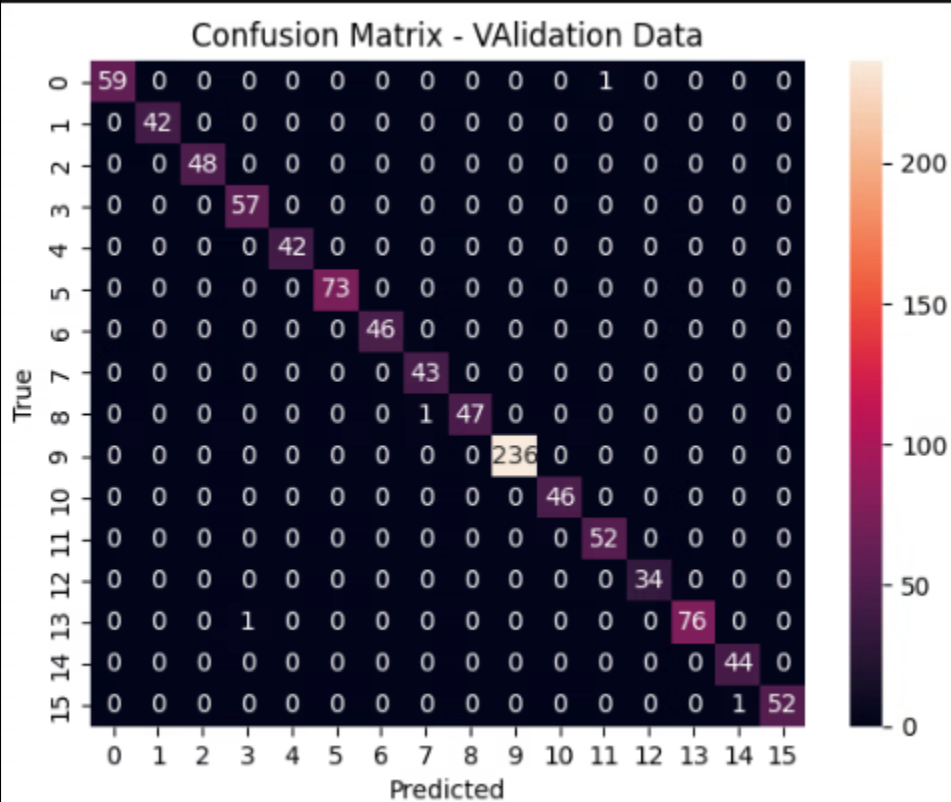
6. Validierungsergebnisse

Nach dem Training und der Validierung der Modelle wurden die folgenden Ergebnisse erzielt. Diese Ergebnisse umfassen die Validierungsverluste, die Genauigkeit sowie die detaillierten Klassifikationsberichte und Verwirrungsmatrizen für die verschiedenen Interaktionstypen (Reposition, Context menu, bimanuelle Keyboard und rescale.)

6.1 Reposition-Modell

32/32 [=====] - 0s 5ms/step - loss: 0.0581 - accuracy: 0.9960
 Validation loss: 0.058080267161130905
 Validation accuracy: 0.9960039854049683


	precision	recall	f1-score	support
0	1.00	0.98	0.99	60
1	1.00	1.00	1.00	42
2	1.00	1.00	1.00	48
3	0.98	1.00	0.99	57
4	1.00	1.00	1.00	42
5	1.00	1.00	1.00	73
6	1.00	1.00	1.00	46
7	0.98	1.00	0.99	43
8	1.00	0.98	0.99	48
9	1.00	1.00	1.00	236
10	1.00	1.00	1.00	46
11	0.98	1.00	0.99	52
12	1.00	1.00	1.00	34
13	1.00	0.99	0.99	77
14	0.98	1.00	0.99	44
15	1.00	0.98	0.99	53
accuracy			1.00	1001
macro avg	0.99	1.00	1.00	1001
weighted avg	1.00	1.00	1.00	1001



6.2 Context menu-Modell

```
18/18 [=====] - 0s 5ms/step - loss: 0.0818 - accuracy: 0.9896
Validation loss: 0.08182601630687714
Validation accuracy: 0.9895651936531067
```

	precision	recall	f1-score	support
0	0.97	1.00	0.99	34
1	1.00	1.00	1.00	52
2	0.98	1.00	0.99	44
3	1.00	1.00	1.00	35
4	1.00	0.96	0.98	26
5	1.00	1.00	1.00	37
6	1.00	0.98	0.99	52
7	0.97	0.97	0.97	34
8	0.94	0.94	0.94	17
9	1.00	0.97	0.99	40
10	1.00	1.00	1.00	28
11	1.00	1.00	1.00	61
12	0.95	1.00	0.97	19
13	1.00	0.97	0.98	29
14	0.98	1.00	0.99	43
15	1.00	1.00	1.00	24
accuracy			0.99	575
macro avg	0.99	0.99	0.99	575
weighted avg	0.99	0.99	0.99	575




6.3 Bimanuelle Keyboard-Modell:

85/85 [=====] - 0s 5ms/step - loss: 0.0427 - accuracy: 0.9978

Validation loss: 0.04273631423711777

Validation accuracy: 0.9977818727493286

	precision	recall	f1-score	support
0	1.00	1.00	1.00	164
1	0.99	1.00	0.99	223
2	0.99	1.00	1.00	156
3	1.00	1.00	1.00	223
4	1.00	0.99	0.99	166
5	1.00	1.00	1.00	145
6	1.00	1.00	1.00	97
7	1.00	1.00	1.00	96
8	1.00	1.00	1.00	184
9	0.99	0.98	0.99	187
10	1.00	1.00	1.00	207
11	1.00	1.00	1.00	156
12	1.00	1.00	1.00	196
13	1.00	1.00	1.00	148
14	1.00	1.00	1.00	162
15	1.00	1.00	1.00	195
accuracy			1.00	2705
macro avg	1.00	1.00	1.00	2705
weighted avg	1.00	1.00	1.00	2705




6.4 rescale-Modell:

26/26 [=====] - 0s 5ms/step - loss: 0.0557 - accuracy: 0.9950

Validation loss: 0.055711228400468826

Validation accuracy: 0.9950494766235352

	precision	recall	f1-score	support
0	0.98	1.00	0.99	59
1	1.00	1.00	1.00	42
2	1.00	1.00	1.00	50
3	1.00	1.00	1.00	53
4	1.00	0.97	0.99	35
5	1.00	0.98	0.99	53
6	1.00	1.00	1.00	30
7	1.00	1.00	1.00	48
8	1.00	1.00	1.00	40
9	0.99	1.00	0.99	98
10	1.00	1.00	1.00	85
11	0.96	1.00	0.98	48
12	1.00	0.98	0.99	48
13	1.00	0.98	0.99	44
14	1.00	1.00	1.00	36
15	1.00	1.00	1.00	39
accuracy			1.00	808
macro avg	1.00	0.99	1.00	808
weighted avg	1.00	1.00	1.00	808



7. Optimierung

Diese Phase umfasst die Anwendung spezieller und fortgeschrittene Techniken zur Verbesserung der Vorhersagegenauigkeit, Verbesserung der Modelle-Leistung und die Optimierung von Parametern. Diese sind:

7.1 Window Slicing

Das Ziel war es, die Verhältnis-Daten in kleinere, überlappende Segmente zu unterteilen, um mehr Trainingsbeispiele zu generieren und die zeitlichen Muster in den Daten besser erfassen zu können.

Implementierung: Die Daten wurden in Fenster einer festen Größe unterteilt, wobei sich die Fenster um einen bestimmten Schritt überlappen. Dies erzeugt mehrere Trainingsbeispiele aus einer einzelnen Datenserie, was die Variabilität und Robustheit des Modells erhöht.

7.2 Majority Voting

Majority Voting wurde verwendet, um die endgültige Vorhersage eines Modells aus den Vorhersagen mehrerer Fenster zu bestimmen.

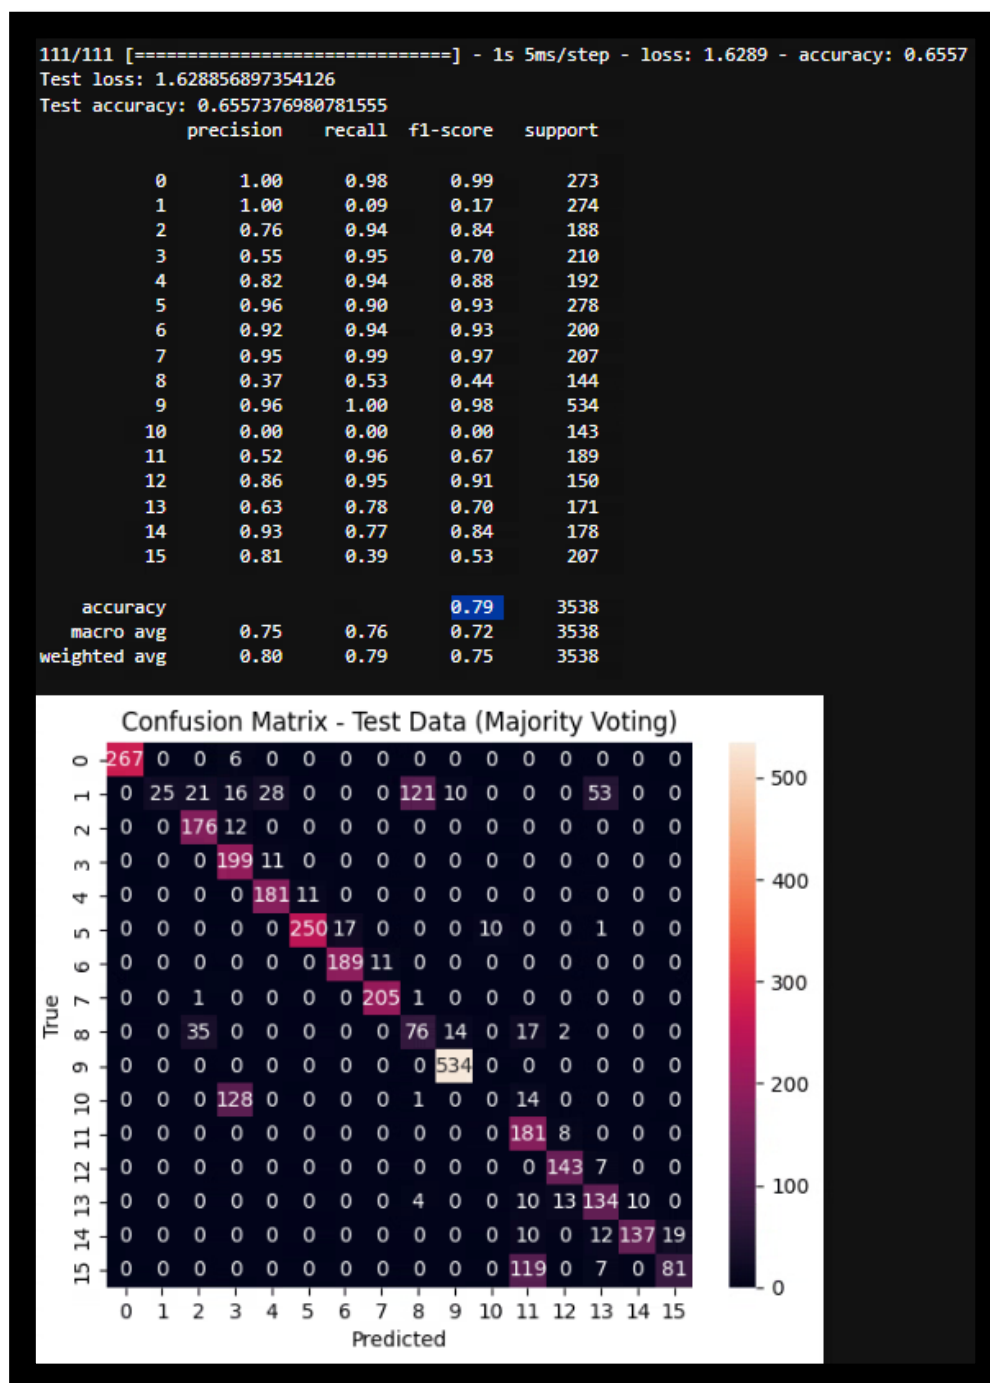
Implementierung: Nach der Vorhersage für jedes Fenster wurde eine Mehrheitsabstimmung innerhalb der Fenster durchgeführt, um die endgültige Klassifikation zu bestimmen. Dies hilft, Rauschen in den Vorhersagen zu reduzieren, die Vorhersagegenauigkeit zu verbessern und die Robustheit der Klassifikation zu erhöhen.

8. Test-Ergebnisse nach der Optimierung:

In diesem Abschnitt werden die Auswirkungen der angewendeten Optimierungstechniken, insbesondere Majority Voting, auf die Modelleistung detailliert dargestellt. Ziel der Optimierungen war es, die Vorhersagegenauigkeit und die Robustheit der Modelle zu verbessern. Die Ergebnisse zeigen die Veränderungen in Verlust und Genauigkeit vor und nach der Anwendung von Majority Voting für verschiedene Interaktionen. Darüber hinaus werden Bilder der Klassifikationsberichte und Verwirrungsmatrizen für jede Interaktion präsentiert, um die Performanceverbesserungen visuell zu veranschaulichen.

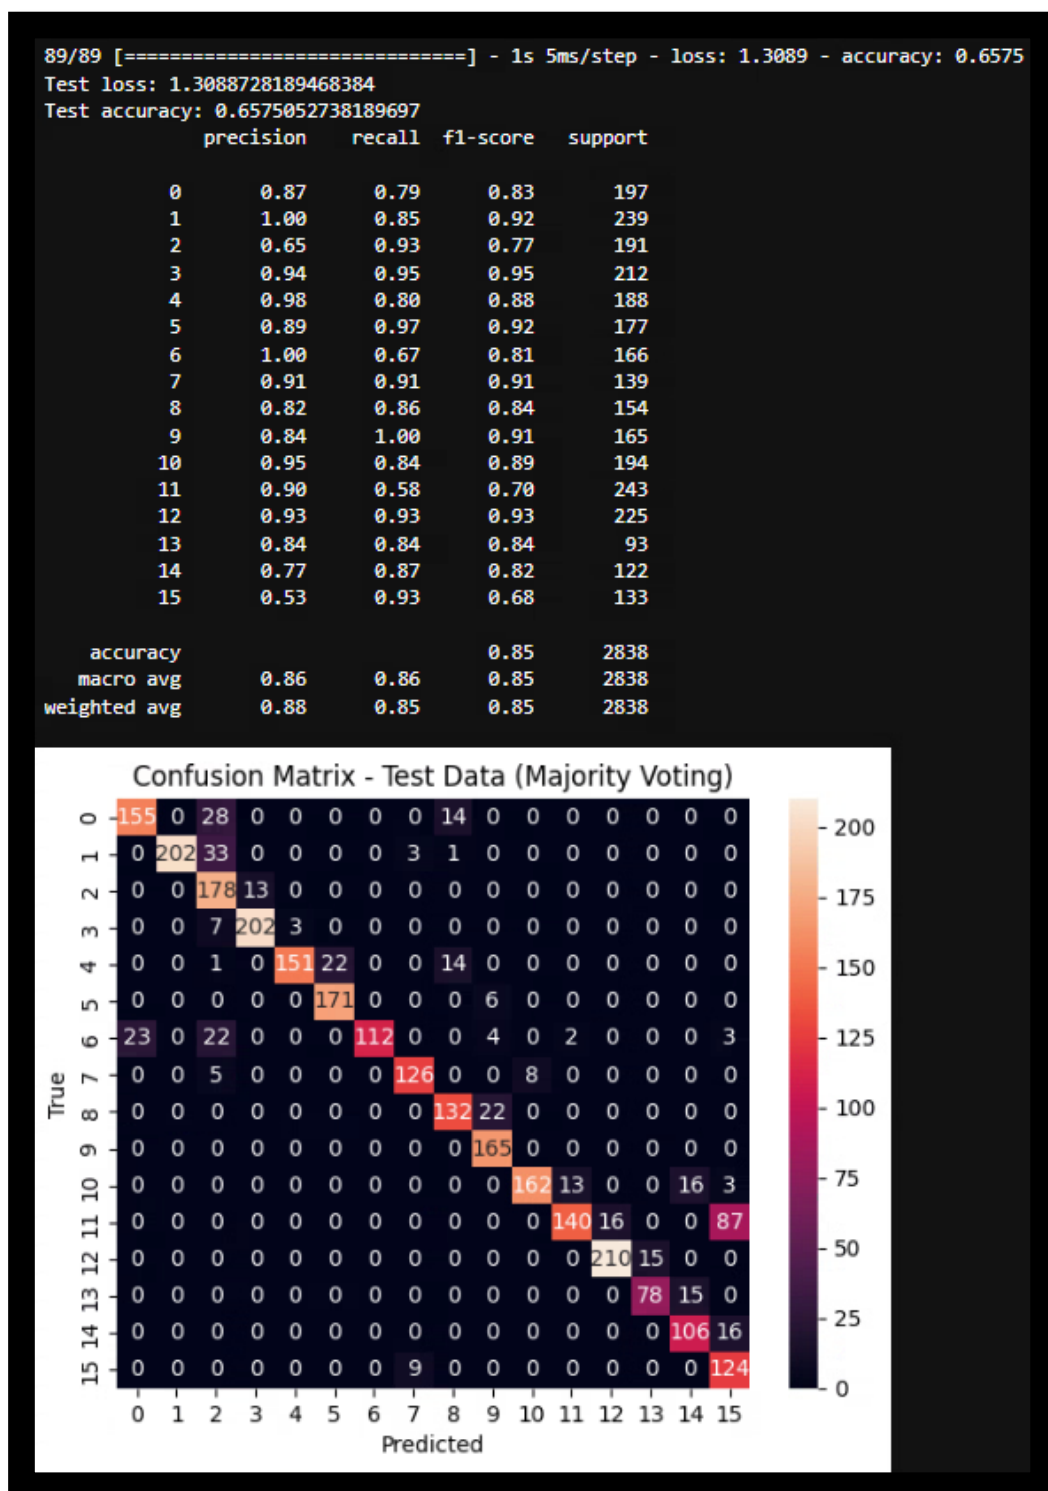
8.1 Reposition

Reposition	Vor Majority Voting	Nach Majority Voting
Loss	1,6288	1,6288
Accuracy	0,6557	0,79



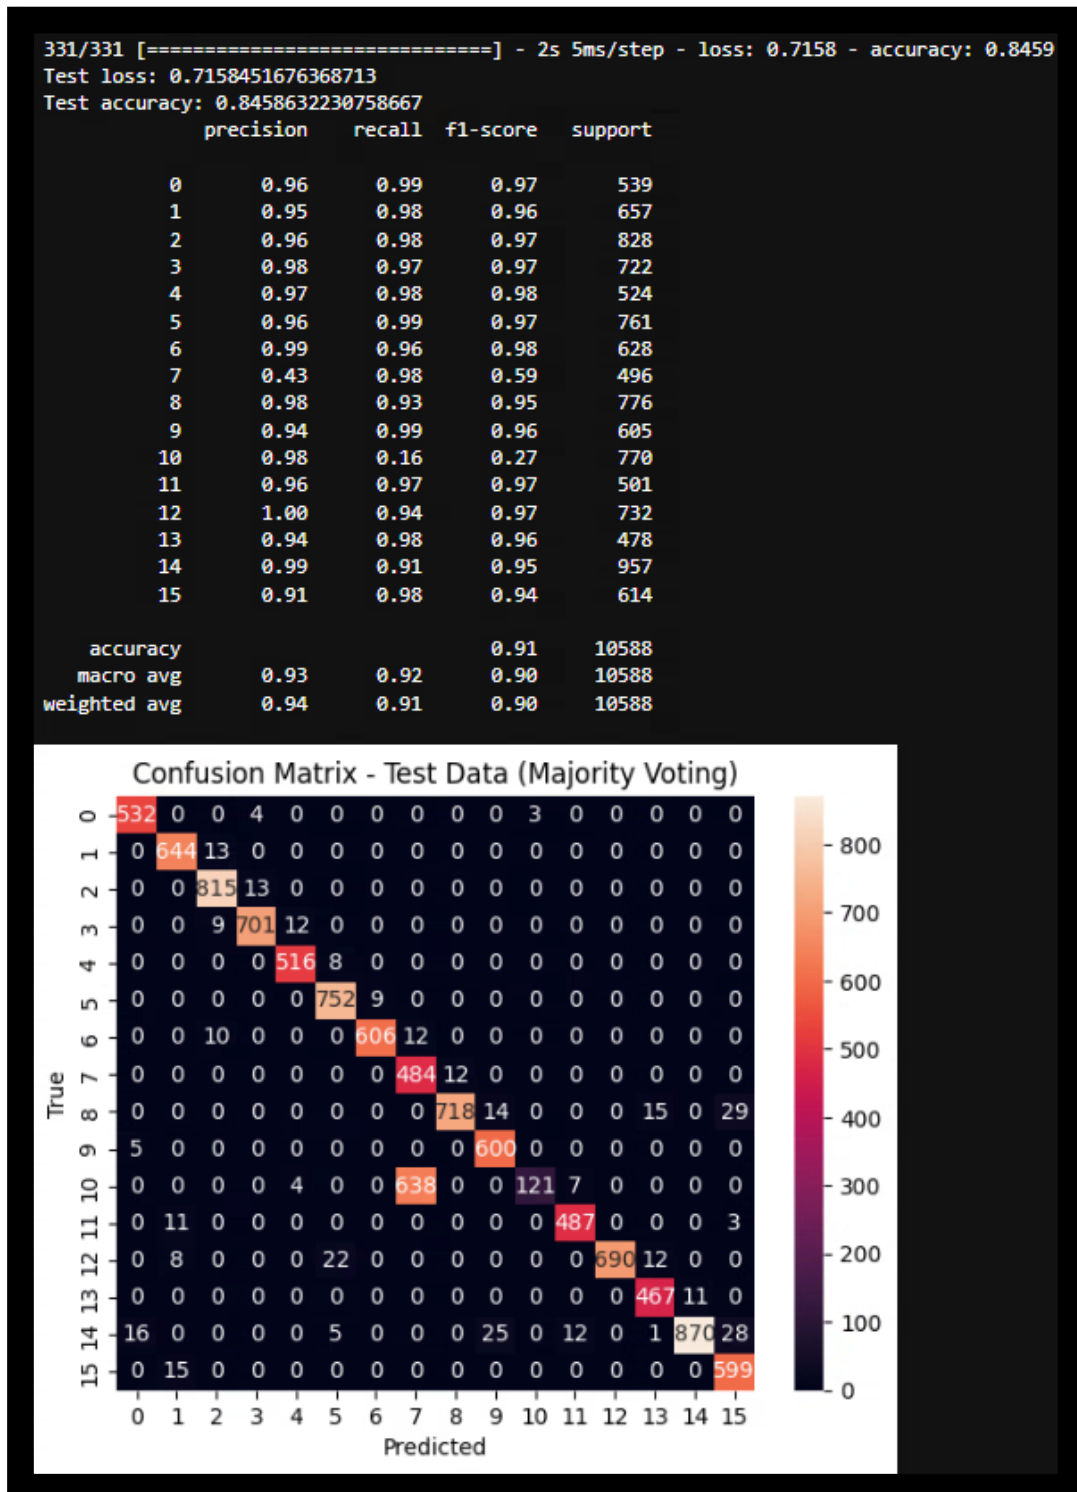
8.2 Context menu

Context menu	Vor Majority Voting	Nach Majority Voting
Loss	1,3089	1,3089
Accuracy	0,6575	0,85



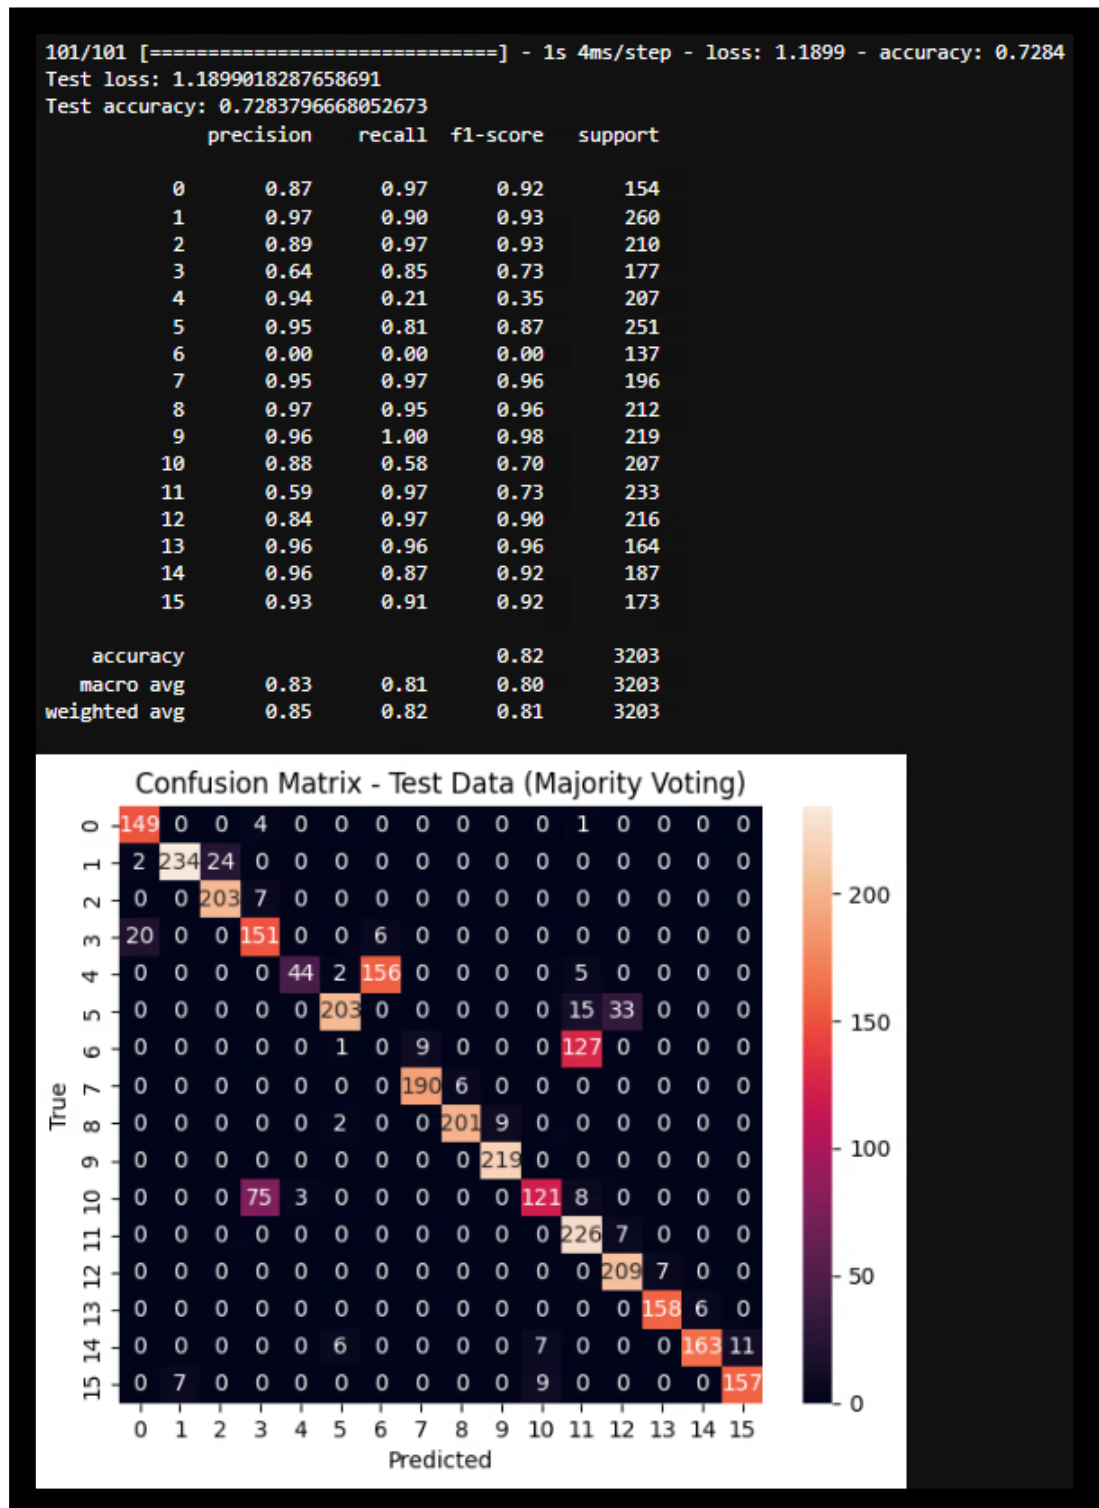
8.3 Bimanuale Keyboard

Bi. Keyboard	Vor Majority Voting	Nach Majority Voting
Loss	0,7159	0,7159
Accuracy	0,8460	0,91



8.4 Rescale

Rescale	Vor Majority Voting	Nach Majority Voting
Loss	1,1899	1,1899
Accuracy	0,7284	0,82



9. Diskussion & Fazit

9.1 Diskussion

Dieses Projekt zeigt das Potenzial von Verhaltensbiometrie zur Identifikation von Benutzern in virtuellen Umgebungen. Durch die Verwendung fortschrittlicher Modellierungstechniken und die Implementierung spezieller Verbesserungsmethoden wie Window Slicing und Majority Voting konnten wir eine hohe Genauigkeit und Zuverlässigkeit bei der Benutzeridentifikation erreichen. Die erzielten Ergebnisse sind vielversprechend und zeigen, dass die entwickelten Modelle in der Lage sind, die meisten Benutzer korrekt zu identifizieren.

Die Verwendung von LSTM-Schichten und die gezielte Optimierung der Hyperparameter haben wesentlich zur Leistungssteigerung beigetragen. Die Anwendung von Window Slicing hat es ermöglicht, die zeitlichen Muster in den Daten besser zu erfassen, während Majority Voting die Vorhersagegenauigkeit durch die Reduktion von Rauschen verbessert hat. Diese Kombination von Techniken stellt sicher, dass die Modelle robust und zuverlässig sind.

9.2 Fazit

Zusammenfassend zeigt dieses Projekt, dass die Verwendung von Handtracking-Daten und fortschrittlichen Machine-Learning-Techniken zur Identifikation von Benutzern in VR-Anwendungen effektiv ist. Die Modelle erzielten eine hohe Genauigkeit und Rückrufrate, was die Machbarkeit und den Nutzen dieses Ansatzes unterstreicht. Zukünftige Arbeiten könnten darauf abzielen, die Modelle weiter zu optimieren und ihre Leistung auf größeren und vielfältigeren Datensätzen zu validieren. Diese Ergebnisse legen den Grundstein für die Entwicklung sicherer und benutzerfreundlicher Authentifizierungssysteme in virtuellen Realitäten.